

주간 기술 세미나 · 조사와 실습

기업 온프레미스 AI Hermes 실습과 PoC

기업 도입 사례 → Agent 실습 → 검증 결과

AI를 어디에 배치하고, 어떤 일을 맡길 것인가?
기업 조사와 직접 실습한 결과를 구분해 살펴본다.

온프레미스 AI

Agent · PoC

조사·비교



요구사항·설계



구현·실습·검증

목차

오늘 다룰 질문

데이터 통제와 작업 자동화,
각각 무엇을 검증해야 할까?

발표 목표

도입 조건을 비교하고
실습 성과와 남은 과제를 판단한다.

1

조사·비교

배경 · 기업 사례

비교표

2

설계·구현

요구사항 · 설계

구현 과정

3

검증·정리

실습 · 테스트

한계 · 향후 과제

조사 배경

현재 상황

기업의 생성형 AI 활용
대화에서 도구 실행으로

해결할 문제

민감 데이터의 외부 전송
자동 실행 결과의 신뢰성
도입 조건과 검증 기준 필요

조사 질문

배치 위치는 데이터 통제, Agent는 작업 실행의 문제다.

범위: 기업 사례 4개 조사 문서 + Hermes 실습 + CRUD PoC 기록

기업 사례

미래에셋증권 · 금융 sLLM

목적: 보안 제약 속 금융 AI 활용
기술: HCX-DASH 기반 금융 sLLM
범위: 온프레미스 구축 완료
효과: 정량 성과는 본 자료에 미제시
출처: NAVER 공식 발표 · 2024.09.19

Lockheed Martin · AI Factory

목적: 내부 AI 활용 확대와 데이터 통제
기술: DGX SuperPOD 기반 AI Factory
범위: 내부 모델·개발 지원 활용
규모: 엔지니어·개발자 7,000명 지원
출처: NVIDIA 고객 사례

시사점: 데이터 통제 요구를 먼저 정의하고, 사용 규모와 운영 역량을 함께 평가한다.

기술 비교표

비교 기준	온프레미스	클라우드 API	확인할 조건
데이터 경로	내부 통제 가능	외부 전송 경로 존재	로그·보관·전송 설정
도입·운영	자원 확보·운영 필요	인프라 부담 감소	담당 인력·운영 책임
비용 구조	장비·전력·유지보수	사용량·계약에 영향	동일 사용량의 총비용
선택 기준	통제 요구가 높을 때	빠른 도입이 중요할 때	품질·지연은 직접 측정


판단: 민감도·사용량·운영 역량으로 선택 — 이번 PoC는 배치 방식 비교 실험이 아니다.

요구사항

ID / 구분	요구사항	우선순위	인수 조건
FR-01 / 기능	User 생성·조회·수정·삭제	필수	정상 요청에 200 / 201
FR-02 / 예외	중복 이메일·없는 사용자	필수	중복 400 / 없는 ID 404
검증 / 실행	로컬 API 동작 확인	필수	TestClient + 실제 HTTP


범위: User CRUD와 오류 처리 제외: 인증·부하 시험·운영 배포

설계



설계 의도: 작은 CRUD 범위로 코드 생성 → 실행 → 수정 → 재시험 흐름을 확인

구현 과정



산출물

요구 분석 → 파일 생성 → 의존성 설치 → 테스트 → 오류 수정

422 오류: Depends(SessionLocal) → Depends(get_db)로 변경 후 재시행

실습 기록 .

실습 기록 요약

Memory

4개 규칙 저장 → 새 세션에서 명시 조회 성공
자동으로 활용하는지는 확인하지 못함

사용자 Skill

생성·저장 → 명시 호출 성공
자동 선택에서는 다른 Skill을 호출한 사례 존재

실습 조건

Windows 11 · Git Bash
새 세션에서 재호출

관찰한 결과

Memory 저장·조회 성공
Skill 명시 호출 성공

자동 적용은 별도 검증 필요

테스트 결과

테스트 묶음	기대 결과	기록된 결과	판정
정상 CRUD · 8건	200 / 201	8건 기대 응답	통과
중복 이메일 · 1건	400	400	통과
없는 ID · 2건	조회·삭제 404	각각 404	통과

환경: Windows 11 · TestClient 근거: 「간단한 PoC 구현 결과」의 실행 기록

주의: 문서에 기록된 결과이며 재실행 검증은 아님. Uvicorn 일부 라우트 문제는 미해결.

기록 11건

통과 11건

서버 검증 미완료

부분 검증

한계

확인한 범위


파일·코드 생성과 터미널 실행
CRUD 테스트 및 일부 오류 수정
Memory 저장·명시 조회
사용자 skill 생성·명시 호출

한계와 미검증 항목

Uvicorn 라우트 문제 미해결
Memory·Skill 자동 적용 불확실
웹 추출 실패와 답변 근거 불일치
모델·추론 위치·성능 조건 미기록

적용 전 확인: 도구 권한·변경 이력·출처·재현 로그 — 자율 실행이 정확성을 보장하지는 않는다.

도입은 조건으로 판단하고 자동화는 증거로 검증한다



다음: 서버 문제 재현 → 자동 호출 검증 → 온프레미스 조건 확인